Data Analytics / Data Analysis

ANALYSE DES PERFORMANCES DES CAMPAGNES MARKETING

Exploration, analyse et visualisation
de 200 005 campagnes marketing

Réalisé par

Manassé Lumu Bamanoa

Data Analytics / Data Analysis

Étude réalisée le 21 septembre 2026

MediJr

https://github.com/MediJr

RÉSUMÉ

Ce rapport documente un projet d'analyse de performances de campagnes marketing, réalisé sur un jeu de **200 005** campagnes observées du 1er janvier au 31 décembre 2021. L'objectif est d'explorer, de décrire et de restituer les indicateurs de performance (ROI, coût d'acquisition, conversion, CTR, engagement) selon les entreprises, types de campagnes, canaux, audiences, segments, localisations et la période, sans inférence causale.

Les données sources proviennent d'un fichier Excel, chargées dans PostgreSQL (MARKETING_ANALYSIS, table `public.marketing_campaigns`), explorées en SQL, extraites vers `Pandas`, profilées, analysées (EDA), visualisées avec `Matplotlib` puis restituées dans un dashboard `Streamlit`. Le stockage repose sur une table relationnelle unique, volontairement sans modèle en étoile ni en flocon.

Les résultats principaux sont descriptifs : volumes très équilibrés entre modalités ; rythme d'environ 548 campagnes par jour civil ; ROI moyen de 5,0024, stable d'une dimension à l'autre ; CTR moyen de 14,04 % contre une médiane de 9,98 % ; seules corrélations notables entre CTR, clics et impressions, liées à la définition du ratio. Aucune anomalie de qualité n'a été détectée.

Mots-clés : Data Analytics, PostgreSQL, SQL, Python, Pandas, Data Visualization, Streamlit, Marketing Analytics.

TABLE DES MATIÈRES

Résumé . . . . . **i**

Table des matières . . . . . **ii**

Liste des figures . . . . . **iv**

Liste des tableaux . . . . . **v**

Liste des abréviations . . . . . **vi**

Chapitre 1 : Introduction **1**
1.1 Contexte 1
1.2 Problématique 1
1.3 Objectif général 1
1.4 Objectifs spécifiques 2
1.5 Périmètre 2
1.6 Organisation du rapport 2

Chapitre 2 : Présentation du jeu de données **3**
2.1 Vue d'ensemble 3
2.2 Modalités catégorielles 3
2.3 Variables principales 4
2.4 Dictionnaire de données 4

Chapitre 3 : Architecture et pipeline **5**
3.1 Chaîne technique 5
3.2 Rôle de chaque étape 6

Chapitre 4 : Stockage et exploration SQL **7**
4.1 Base et table 7
4.2 Import et contrôles 7
4.3 Analyses SQL 7

Chapitre 5 : Extraction et préparation Python **9**
5.1 Connexion et extraction 9
5.2 Contrôle des types 9
5.3 Préparation 9
5.4 Contrôles qualité 10

Chapitre 6 : Analyse exploratoire **11**
6.1 KPI globaux 11
6.2 Entreprises, types, canaux, audiences, segments, localisations 11
6.3 Temps et durée 12
6.4 Classes de ROI, CTR, conversion et engagement 12
6.5 Corrélations et croisements 13

Chapitre 7 : Visualisations **14**
7.1 Volume par entreprise 14
7.2 Volume mensuel 14
7.3 Distribution du CTR 15
7.4 Corrélations 16
7.5 ROI selon la classe de CTR 16

Chapitre 8 : Dashboard Streamlit **18**
8.1 Architecture 18
8.2 Filtres et KPI 18
8.3 Organisation des vues 18
8.4 Emplacement pour une capture 19

Chapitre 9 : Résultats et constats **20**

Chapitre 10 :Limites de l'analyse **21**

Chapitre 11 :Conclusion **22**

Chapitre A : Contrôles qualité **23**

Chapitre B : Tableaux SQL complémentaires **24**
B.1 Volumes par entreprise 24
B.2 Classes de ROI (`CASE`) 24
B.3 Types de campagnes 25

Chapitre C : Visualisations complémentaires **26**

Chapitre D : Structure du projet et scripts **32**

Bibliographie **33**

LISTE DES FIGURES

3.1 Pipeline analytique du projet (table relationnelle unique) 5

7.1 Répartition des campagnes par entreprise (volumes, pas un classement de performance) 14
7.2 Volume mensuel et campagnes par jour civil en 2021 (échelle quotidienne 540–556) 15
7.3 Distribution du CTR (%) 15
7.4 Corrélations de Pearson entre variables numériques 16
7.5 ROI selon la classe de CTR 17

8.1 Emplacement prévu pour une capture du dashboard (non disponible au moment de la rédaction) 19

C.1 Volume par type de campagne 26
C.2 Volume par canal 26
C.3 ROI moyen mensuel (écarts faibles) 27
C.4 Distribution du ROI 27
C.5 Distribution du coût d'acquisition 28
C.6 Distribution discrète du taux de conversion 28
C.7 Distribution du ROI par classe de ROI 29
C.8 ROI moyen : audience $\times$ segment 29
C.9 ROI moyen : entreprise $\times$ canal (pas un classement) 30
C.10 ROI selon la durée de campagne 30
C.11 ROI moyen selon le score d'engagement 31

LISTE DES TABLEAUX

1 Abréviations utilisées dans le rapport vi

2.1 Caractéristiques générales du jeu de données 3
2.2 Dictionnaire de données synthétique (colonnes sources) 4

5.1 Contrôles de préparation (Pandas) 10

6.1 KPI globaux sur 200 005 campagnes 11
6.2 Étendue des volumes et du ROI moyen par dimension 12
6.3 KPI par trimestre 12

A.1 Synthèse des contrôles de qualité 23

B.1 Campagnes par entreprise (SQL / briefing) 24
B.2 Classes de ROI calculées en SQL 24
B.3 Effectif et ROI moyen par type de campagne 25

D.1 Scripts analytiques du projet 32

LISTE DES ABRÉVIATIONS

Abréviation	Définition
CTR	Click-Through Rate (clics / impressions)
EDA	Exploratory Data Analysis (analyse exploratoire)
KPI	Key Performance Indicator (indicateur de performance)
ROI	Return on Investment (retour sur investissement)
SQL	Structured Query Language
SGBD	Système de gestion de bases de données

TABLE 1 – Abréviations utilisées dans le rapport

Chapitre 1

INTRODUCTION

1.1 Contexte

Le projet porte sur l'analyse de performances d'un ensemble de campagnes marketing. Les données sont disponibles sous forme d'un fichier Excel (`marketing_campaign_dataset.xlsx`), puis stockées dans PostgreSQL et analysées en SQL et en Python. Le travail documenté ici reprend exclusivement les étapes réellement réalisées : import, exploration SQL, extraction Pandas, profilage, analyse exploratoire, visualisations Matplotlib, revue des graphiques et dashboard Streamlit THE PANDAS DEVELOPMENT TEAM, 2026 ; HUNTER et THE MATPLOTLIB DEVELOPMENT TEAM, 2026 ; STREAMLIT INC., 2026 ; THE POSTGRESQL GLOBAL DEVELOPMENT GROUP, 2025.

Aucune hypothèse de marché, de budget publicitaire ou d'organisation interne n'est ajoutée : le rapport s'en tient aux variables et aux résultats observés dans le jeu de données SOURCE DU PROJET, 2021.

1.2 Problématique

Comment décrire, de façon reproductible et honnête, les performances de 200 005 campagnes marketing de l'année 2021, selon les entreprises, les types de campagnes, les canaux, les audiences, les segments, les localisations et la période, sans transformer une association statistique en relation causale ?

1.3 Objectif général

Construire une chaîne d'analyse allant du fichier Excel jusqu'à une restitution interactive, en conservant l'intégrité des données sources et en produisant des indicateurs et des graphiques validés.

1.4 Objectifs spécifiques

Objectifs :

- Stocker les 200 005 campagnes dans PostgreSQL, dans une table unique contrainte.
- Explorer les volumes et les KPI en SQL (agrégations, `GROUP BY`, `HAVING`, `CASE`).
- Extraire le résultat vers Pandas, contrôler les types et préparer des indicateurs calendaires et le CTR.
- Réaliser une EDA exhaustive sans graphique, puis 16 visualisations Matplotlib revues.
- Restituer les résultats dans un dashboard Streamlit filtrable, avec export CSV du sous-ensemble affiché.

1.5 Périmètre

Le périmètre est le fichier Excel du projet, la base MARKETING_ANALYSIS, la table `public.marketing_c` et les scripts Python associés. La période couverte par les dates de campagne est le 1er janvier 2021 au 31 décembre 2021. Le grain est une ligne = une campagne.

Hors périmètre : Power BI, Tableau, Seaborn, Plotly, modélisation prédictive, modèle dimensionnel en étoile ou en flocon, et toute modification des données sources après import.

1.6 Organisation du rapport

Le Chapitre 2 décrit le jeu de données. Le Chapitre 3 présente le pipeline. Les Chapitre 4 et Chapitre 5 documentent le stockage SQL puis l'extraction Python. Le Chapitre 6 synthétise l'EDA, le Chapitre 7 les graphiques validés et le Chapitre 8 le dashboard. Les Chapitre 9 et Chapitre 10 rassemblent constats et limites, avant la conclusion et les annexes.

Chapitre 2

PRÉSENTATION DU JEU DE DONNÉES

2.1 Vue d'ensemble

Le fichier source Excel contient **200 005** campagnes et **15** colonnes. Après import PostgreSQL, la table conserve ces 15 colonnes. Après préparation Pandas, le DataFrame d'analyse en compte 21 (ajout de `year`, `month`, `month_name`, `quarter`, `ctr` et `ctr_percent`).

TABLE 2.1 – Caractéristiques générales du jeu de données

Caractéristique	Valeur observée
Nombre de campagnes	200 005
Colonnes originales	15
Période des dates de campagne	2021-01-01 → 2021-12-31
Entreprises	5
Types de campagnes	5
Canaux	6
Audiences cibles	5
Segments clients	5
Localisations	5

2.2 Modalités catégorielles

Les modalités suivantes ont été observées dans PostgreSQL et confirmées par l'EDA.

- **Entreprises :** TechCorp, Alpha Innovations, DataTech Solutions, NexGen Systems, Innovate Industries.
- **Types :** Influencer, Search, Display, Email, Social Media.
- **Canaux :** Email, Google Ads, YouTube, Instagram, Website, Facebook.
- **Audiences :** Men 18-24, Men 25-34, Women 25-34, Women 35-44, All Ages.

- **Segments :** Fashionistas, Foodies, Health & Wellness, Outdoor Adventurers, Tech Enthusiasts.
- **Localisations :** Miami, New York, Chicago, Los Angeles, Houston.

Les volumes sont quasi uniformes (environ 20 % pour les variables à cinq modalités, environ 16,7 % pour les six canaux). Toutes les combinaisons entreprise × canal (30), type × canal (30) et audience × segment (25) sont présentes.

2.3 Variables principales

Les indicateurs numériques utilisés tout au long du projet sont le ROI, le coût d'acquisition, le taux de conversion, les clics, les impressions, le score d'engagement, la durée et la date de campagne. Le CTR n'est pas une colonne source : il est calculé après extraction, campagne par campagne, comme le rapport clics / impressions.

2.4 Dictionnaire de données

TABLE 2.2 – Dictionnaire de données synthétique (colonnes sources)

Colonne	Type PG	Rôle
`campaign_id`	`INTEGER` PK	Identifiant unique de campagne (1 à 200 005)
`company`	`TEXT`	Entreprise à l'origine de la campagne
`campaign_type`	`TEXT`	Type de campagne
`target_audience`	`TEXT`	Audience ciblée
`duration_days`	`INTEGER`	Durée en jours (15, 30, 45 ou 60)
`channel_used`	`TEXT`	Canal utilisé
`conversion_rate`	`NUMERIC(4,2)`	Taux de conversion (0,01 à 0,15)
`acquisition_cost`	`NUMERIC(12,2)`	Coût d'acquisition de la campagne
`roi`	`NUMERIC(4,2)`	Retour sur investissement
`location`	`TEXT`	Localisation
`campaign_date`	`DATE`	Date de campagne
`clicks`	`INTEGER`	Nombre de clics
`impressions`	`INTEGER`	Nombre d'impressions
`engagement_score`	`SMALLINT`	Score d'engagement (1 à 10)
`customer_segment`	`TEXT`	Segment client

La colonne Excel `Duration` (texte du type `"15 days"`) a été convertie en entier de jours à l'import. La colonne `Date` a été convertie en type `DATE`.

Chapitre 3

ARCHITECTURE ET PIPELINE

3.1 Chaîne technique

Le projet suit une chaîne linéaire, chaque étape consommant le résultat de la précédente sans réécrire PostgreSQL ni le fichier Excel une fois l'import effectué.

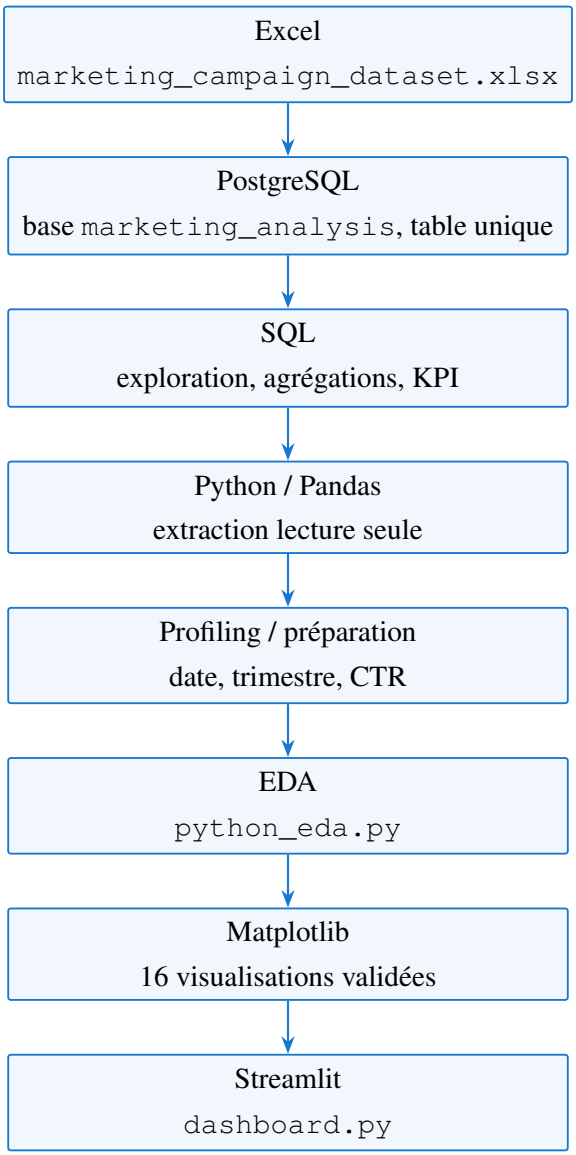


FIGURE 3.1 – Pipeline analytique du projet (table relationnelle unique)

3.2 Rôle de chaque étape

1. **Excel.** Jeu source, non modifié après import.
2. **PostgreSQL.** Stockage structuré, contraintes, point de vérité pour les analyses SQL THE POSTGRESQL GLOBAL DEVELOPMENT GROUP, 2025.
3. **SQL.** Lectures seules : volumes, moyennes, `CASE`, `HAVING`, analyses croisées et temporelles.
4. **Python / Pandas.** Extraction `SELECT *` ordonnée par `campaign_id`, inspection des types et de la mémoire THE PANDAS DEVELOPMENT TEAM, 2026 ; BAYER et THE SQLALCHEMY AUTHORS, 2025.
5. **Profiling.** Contrôle des nulls, unicité de `campaign_id`, conversion de la date, création des colonnes calendaires et du CTR.
6. **EDA.** Analyses A à S dans Pandas, sans graphique.
7. **Matplotlib.** Seize figures PNG, puis revue : seule l'échelle du rythme quotidien du graphique mensuel a été corrigée HUNTER et THE MATPLOTLIB DEVELOPMENT TEAM, 2026.
8. **Streamlit.** Restitution filtrable des KPI et graphiques, export CSV du sous-ensemble affiché STREAMLIT INC., 2026.

Choix d'architecture

Le projet utilise volontairement **une table relationnelle unique**. Il n'y a pas de modèle en étoile, ni en flocon, ni de tables de faits et de dimensions séparées.

Chapitre 4

STOCKAGE ET EXPLORATION SQL

4.1 Base et table

La base MARKETING_ANALYSIS a été créée sur PostgreSQL local (hôte `127.0.0.1`, port 5432). Le rôle d'application est `data_project`. La table `public.marketing_campaigns` reprend les 15 colonnes source, en `snake_case`.

Les types retenus sont : `INTEGER` pour l'identifiant, les clics, les impressions et la durée ; `SMALLINT` pour l'engagement ; `NUMERIC` pour le ROI, le coût et la conversion ; `DATE` pour la date ; `TEXT` pour les catégories. Toutes les colonnes sont `NOT NULL`. `campaign_id` est clé primaire.

Contraintes `CHECK` posées à la création :

- `acquisition_cost >= 0;`
- `conversion_rate BETWEEN 0 AND 1;`
- `clicks <= impressions;`
- `engagement_score BETWEEN 1 AND 10.`

4.2 Import et contrôles

Les 200 005 lignes ont été importées depuis Excel (conversion de la durée texte vers un entier de jours, et de la date vers `DATE`). Les contrôles de qualité en base et en Pandas donnent : 0 valeur manquante, identifiants uniques de 1 à 200 005, dates strictement dans l'année 2021, aucune anomalie bloquante.

4.3 Analyses SQL

Les requêtes d'exploration sont des `SELECT` en lecture seule. Elles ont servi à :

- **Agrégations et `GROUP BY`.** Volumes et ROI moyen par type, entreprise, canal, audience, segment, localisation, mois.

- **KPI.** `COUNT`, `AVG` sur ROI, coût, conversion, engagement ; CTR calculé soit comme moyenne des ratios individuels, soit comme $\sum$ clics / $\sum$ impressions (ces deux définitions ne coïncident pas, d'où l'écart entre CTR moyen $\approx$ 14 % et CTR global $\approx$ 10 %).
- **`CASE`.** Classes de ROI (faible < 4, moyen $[4,6[$, élevé ≥ 6) : 66 503 / 66 438 / 67 064 campagnes, ROI moyens 2,99 / 5,00 / 7,00.
- **`HAVING`.** Filtres après agrégation, par exemple pour n'afficher que des groupes dépassant un seuil d'effectif ou de KPI.
- **Analyses croisées.** Tous les couples entreprise $\times$ canal et type $\times$ canal existent ; les volumes par couple sont du même ordre de grandeur.
- **Analyse temporelle.** Volume mensuel aligné sur le nombre de jours du mois ; rythme proche de 548 campagnes/jour.

```sql
SELECT
    campaign_type,
    COUNT(*) AS campaign_count,
    AVG(roi) AS avg_roi
FROM public.marketing_campaigns
GROUP BY campaign_type
ORDER BY avg_roi DESC;
```

Listing 4.1 – Exemple d'agrégation SQL (ROI moyen par type)

Résultat observé : Influencer 40 170 campagnes (ROI moyen 5,0110), Search 40 157 (5,0084), Display 39 988 (5,0065), Email 39 871 (4,9943), Social Media 39 819 (4,9918). La somme des effectifs vaut 200 005. Les écarts de ROI moyen restent inférieurs à 0,02 : ce n'est pas un classement de performance.

Des tableaux SQL complémentaires figurent en annexe B.

Chapitre 5

EXTRACTION ET PRÉPARATION PYTHON

5.1 Connexion et extraction

Le script `postgres_to_python.py` établit une connexion SQLAlchemy `postgresql+psycopg2` vers `127.0.0.1:5432/marketing_analysis`, avec le rôle `data_project`. Le mot de passe est demandé par `getpass` et n'est jamais inscrit dans le code BAYER et THE SQLALCHEMY AUTHORS, 2025. La requête est :

```sql
SELECT *
FROM public.marketing_campaigns
ORDER BY campaign_id;
```

Listing 5.1 – Extraction complète, lecture seule

Le résultat est chargé par `pandas.read_sql`. Le moteur est fermé dans un `finally` (`engine.dispose()`). Shape à l'extraction : (200005, 15).

5.2 Contrôle des types

À l'arrivée dans Pandas : entiers en `int64`, numériques en `float64`, catégories en `str`, `campaign_date` d'abord en `object`. `df.info()` indique 200 005 non-null sur chaque colonne. Aucune colonne entièrement vide.

5.3 Préparation

Le script `python_dataframe_profiling.py` convertit la date et ajoute six colonnes, sans modifier les 15 colonnes sources :

- `year`, `month`, `month_name`, `quarter` dérivés de `campaign_date` ;
- `ctr` = clics / impressions, avec valeur manquante si impressions nulles (cas non observé) ;
- `ctr_percent` = `ctr` $\times$ 100.

Le DataFrame préparé a pour shape (200005, 21).

5.4 Contrôles qualité

TABLE 5.1 – Contrôles de préparation (Pandas)

Contrôle	Résultat
Shape source (200005, 15)	OK
`campaign_id` unique, min 1, max 200 005	OK
Valeurs manquantes	0
Dates dans [2021-01-01, 2021-12-31]	OK
Cohérence `ctr` = clics / impressions	OK
Colonnes sources inchangées après préparation	OK

Ces contrôles sont repris à l'issue de l'EDA (`python_eda.py`) : 0 NaN, 0 infini, 0 anomalie.

Chapitre 6

ANALYSE EXPLORATOIRE

L'EDA est produite par `python_eda.py`, après le même chargement et la même préparation que le profilage. Les analyses A à S sont faites dans Pandas. Aucun graphique n'est créé à cette étape. Les contrôles post-EDA sont tous OK.

6.1 KPI globaux

TABLE 6.1 – KPI globaux sur 200 005 campagnes

Variable	Moyenne	Médiane	Min	Max	Écart-type
ROI	5,0024	5,0100	2,00	8,00	1,7345
Coût d'acquisition	12 504,44	12 497	5 000	20 000	4 337,66
Taux de conversion	0,0801	0,0800	0,01	0,15	0,0406
CTR (%)	14,04	9,98	1,01	99,20	13,09
Clics	549,77	550	100	1 000	—
Impressions	5 507,31	5 518	1 000	10 000	—
Engagement	5,49	5	1	10	—
Durée (jours)	37,50	30	15	60	—

Le total des coûts d'acquisition vaut 2 500 950 881 (unités de la source). Le CTR moyen (14,04 %) est nettement supérieur à la médiane (9,98 %) : la distribution est asymétrique à droite.

6.2 Entreprises, types, canaux, audiences, segments, localisations

Pour chaque dimension, la somme des volumes vaut 200 005. Les ROI moyens restent autour de 5. Aucun classement « meilleure / pire » n'est établi.

TABLE 6.2 – Étendue des volumes et du ROI moyen par dimension

Dimension	n (min–max)	ROI min–max	Écart ROI
Entreprise	39 711–40 238	4,9914–5,0071	0,016
Type	39 819–40 170	4,9918–5,0110	0,019
Canal	32 820–33 599	4,9887–5,0187	0,030
Audience	39 688–40 259	4,9828–5,0206	0,038
Segment	39 742–40 210	4,9994–5,0043	0,005
Localisation	39 751–40 269	4,9802–5,0123	0,032

Conversion, CTR moyen et engagement restent du même ordre sur toutes ces dimensions (conversion $\approx 0{,}080$, CTR $\approx 14\ \%$, engagement $\approx 5{,}49$, coût $\approx 12\,500$).

6.3 Temps et durée

Le rythme quotidien est d'environ **548** campagnes par jour civil tous les mois (décembre : 547,35). Le volume plus bas de février (15 344) correspond à 28 jours $\times$ 548, et non à une baisse d'activité distincte.

TABLE 6.3 – KPI par trimestre

Trimestre	n	ROI	Coût	Conversion	CTR (%)
Q1	49 320	5,0140	12 489,67	0,0800	14,08
Q2	49 868	5,0009	12 471,62	0,0801	13,99
Q3	50 419	4,9921	12 525,93	0,0799	14,00
Q4	50 398	5,0029	12 529,87	0,0802	14,09

ROI mensuel : minimum 4,9764 (août), maximum 5,0222 (janvier), écart 0,046. Cette variation n'est pas lue comme une tendance.

Les quatre durées (15, 30, 45, 60 jours) représentent chacune environ 25 % des campagnes. L'écart de ROI moyen entre durées est 0,012.

6.4 Classes de ROI, CTR, conversion et engagement

Les classes de ROI (faible < 4, moyen $[4,6[$, élevé ≥ 6) forment trois tiers presque égaux (33,25 %, 33,22 %, 33,53 %). Coût, conversion, CTR et engagement ne séparent pas ces classes.

Le CTR a pour quartiles P25 = 5,86 % et P75 = 16,97 %. Les classes de CTR donnent des ROI moyens de 5,0154 (CTR $<$ 5 %), 4,9985 (5–15 %) et 5,0004 ($\geq$ 15 %).

Le taux de conversion prend 15 valeurs distinctes (0,01 à 0,15). Le ROI moyen par valeur reste dans 4,96–5,04, sans gradient.

Les scores d'engagement de 1 à 10 pèsent chacun environ 10 % (19 882 à 20 141 campagnes). Le ROI moyen par score reste dans 4,98–5,02.

6.5 Corrélations et croisements

La grille descriptive de $|r|$ de Pearson est : $<$ 0,10 négligeable ; 0,10–0,30 faible ; 0,30–0,50 modérée ; 0,50–0,70 notable ; 0,70–0,90 forte ; $\geq$ 0,90 très forte. Une corrélation n'est pas une causalité.

Seules deux paires ont $|r| \geq 0,10$: impressions vs CTR ($r = -0,6575$, notable) et clics vs CTR ($r = +0,5065$, notable). Ces liens sont mécaniques : CTR $=$ clics/impressions. Le ROI n'est associé linéairement ni au CTR, ni à la conversion, ni à l'engagement ($|r| < 0,10$).

Les 30 combinaisons entreprise $\times$ canal, 30 type $\times$ canal et 25 audience $\times$ segment sont toutes observées. Le ROI des cellules reste dans une bande étroite ($\approx$ 4,96–5,04).

Aucune modalité n'est inférée comme dominante ($>$ 40 %) ou minoritaire ($<$ 5 %). L'écart max–min de parts est au plus 0,39 point (canaux).

Chapitre 7

VISUALISATIONS

Les seize figures sont produites par `python_visualisations.py` (Matplotlib, sans Seaborn ni Plotly) et enregistrées dans `visualisations/`. La revue n'a corrigé que `04_volume_mensuel.` (échelle honnête 540–556 campagnes/jour). Les graphiques ci-dessous sont ceux classés essentiels ; les autres sont en annexe C.

7.1 Volume par entreprise

La Figure 7.1 montre des effectifs très proches entre les cinq entreprises (environ 20 % chacune). Les libellés indiquent l'effectif et la part. Ce graphique décrit un volume, pas une performance.

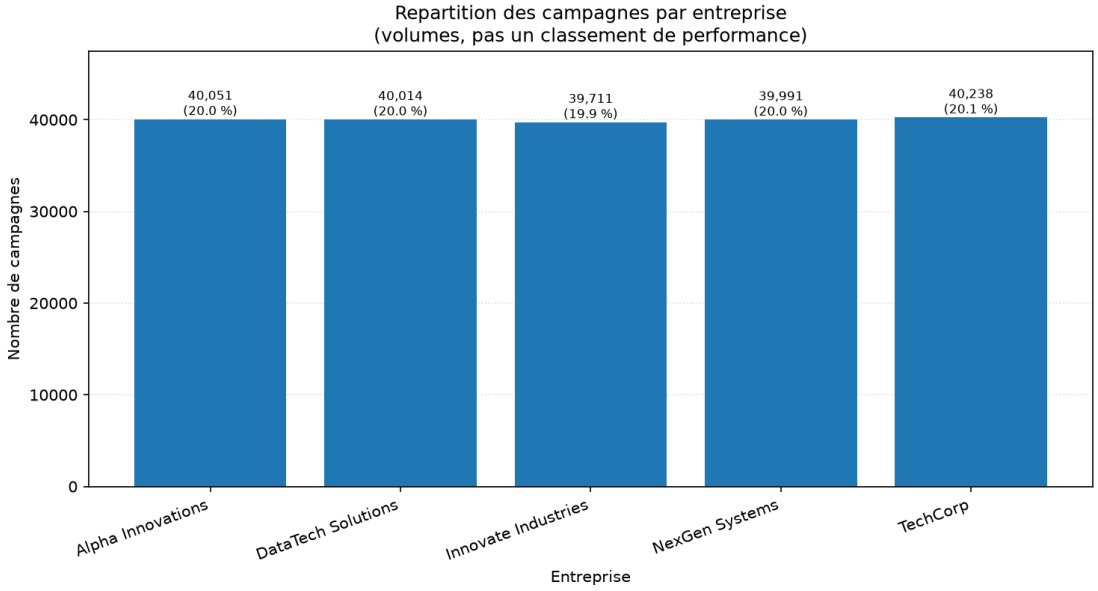


FIGURE 7.1 – Répartition des campagnes par entreprise (volumes, pas un classement de performance)

7.2 Volume mensuel

La Figure 7.2 superpose le volume mensuel brut et le rythme quotidien (n / nombre de jours du mois). Après correction de l'échelle, le rythme apparaît plat, autour de 548 campagnes/jour. Février n'est plus bas que parce qu'il a 28 jours.

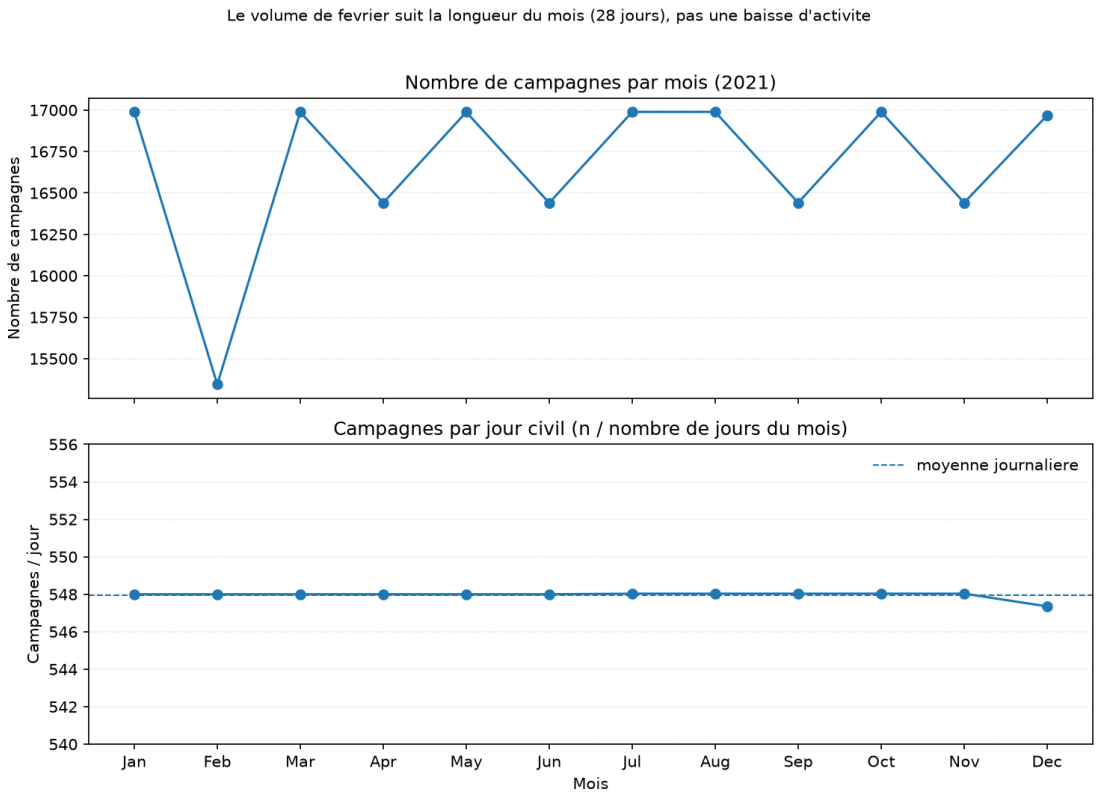


FIGURE 7.2 – Volume mensuel et campagnes par jour civil en 2021 (échelle quotidienne 540–556)

7.3 Distribution du CTR

La Figure 7.3 présente le CTR en pourcentage. La moyenne (14,04 %) est supérieure à la médiane (9,98 %) : asymétrie à droite. L'axe s'étend de 0 à 100 %.

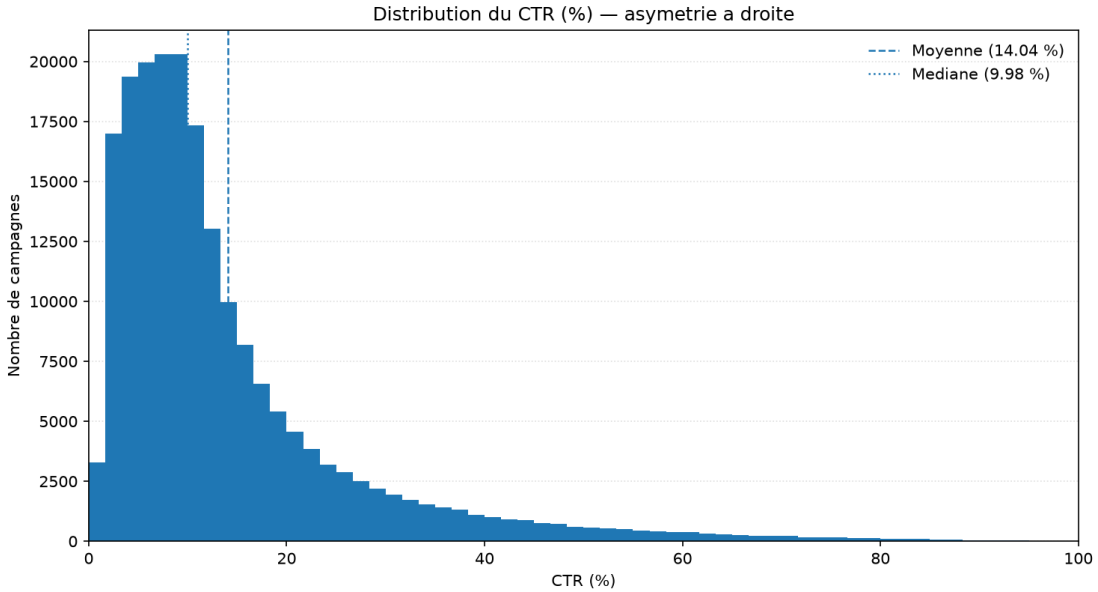


FIGURE 7.3 – Distribution du CTR (%)

7.4 Corrélations

La Figure 7.4 affiche les coefficients de Pearson entre ROI, coût d'acquisition, conversion, clics, impressions, engagement, durée et CTR. Les deux coefficients visuellement saillants concernent CTR–clics et CTR–impressions.

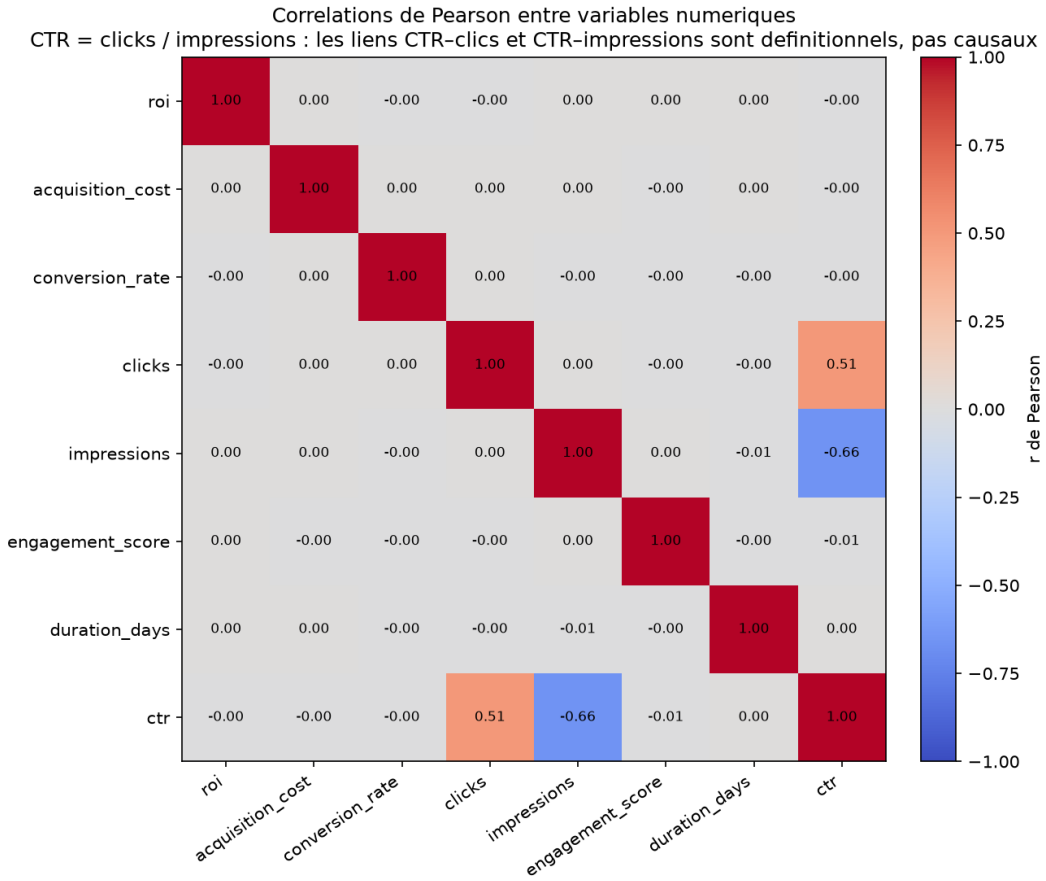


FIGURE 7.4 – Corrélations de Pearson entre variables numériques

Lecture du CTR

CTR = Clicks / Impressions. Les corrélations CTR–Clicks et CTR–Impressions sont liées à la définition du ratio et ne doivent pas être interprétées comme des relations causales.

7.5 ROI selon la classe de CTR

La Figure 7.5 compare les distributions de ROI pour CTR faible (< 5 %), moyen ($[5, 15[$) et élevé (≥ 15 %). Les boîtes restent très proches ; les ROI moyens valent 5,0154, 4,9985 et 5,0004.

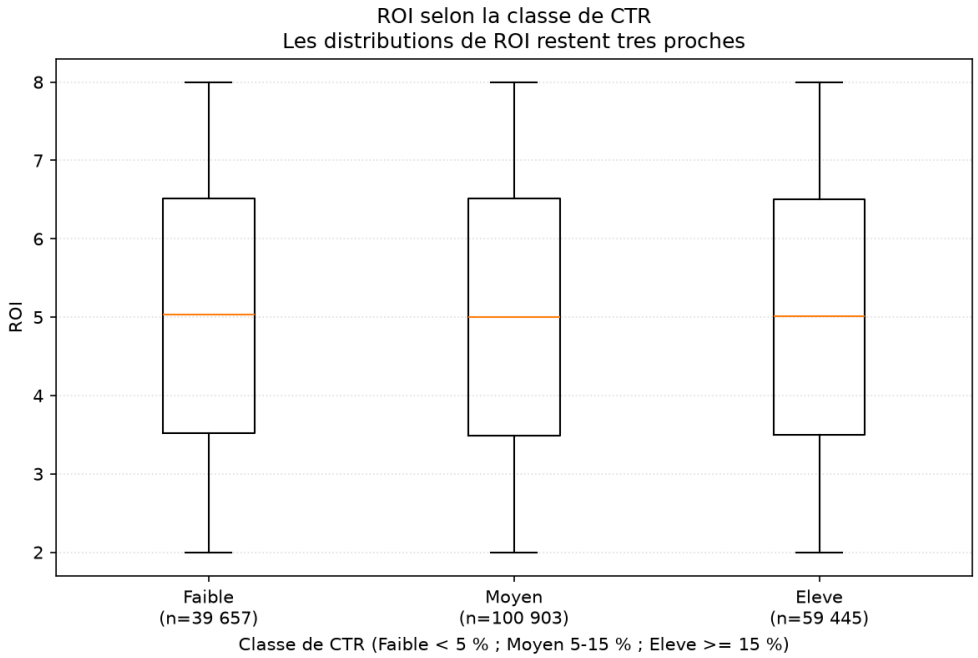


FIGURE 7.5 – ROI selon la classe de CTR

Chapitre 8

DASHBOARD STREAMLIT

8.1 Architecture

Le livrable de restitution est `dashboard.py`, lancé par `streamlit run dashboard.py`. Il s'appuie sur Streamlit, Pandas et Matplotlib uniquement STREAMLIT INC., 2026. Le DataFrame source est chargé une fois depuis PostgreSQL (`@st.cache_data`), en lecture seule. Les filtres produisent un DataFrame distinct ; le DataFrame chargé n'est jamais modifié.

8.2 Filtres et KPI

La barre latérale propose les filtres Company, Campaign Type, Channel, Target Audience, Customer Segment, Location, Quarter et Month, chacun avec l'option « Tous ». Les filtres se combinent. À chaque changement, les KPI et les graphiques concernés sont recalculés sur le sous-ensemble.

Les cartes d'indicateurs affichent : nombre de campagnes, ROI moyen, coût d'acquisition moyen, taux de conversion moyen (en pourcentage), CTR moyen (en pourcentage, par exemple 14,04 % et non 0,1404) et engagement moyen.

8.3 Organisation des vues

Le dashboard reprend la logique des visualisations validées, recalculée dynamiquement :

1. vue d'ensemble (volumes entreprise, type, canal) ;
2. distributions (ROI, coût, conversion, CTR) ;
3. audience, segments et canaux (heatmaps ROI et classes de CTR) ;
4. analyse temporelle (volume mensuel et ROI mensuel, avec échelle prudente) ;
5. corrélations et analyses complémentaires (durée, engagement) ;
6. constats et limites issus de l'EDA.

Un export CSV optionnel, nommé `marketing_campaigns_filtered.csv`, est généré uniquement à partir du DataFrame filtré.

8.4 Emplacement pour une capture

Aucune capture d'écran du dashboard n'est jointe à ce rapport. L'encadré suivant réserve un emplacement pour une future illustration.

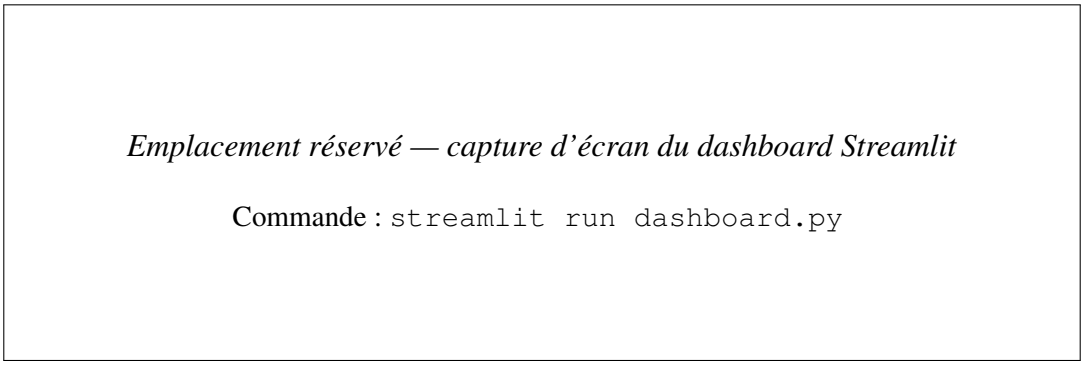


FIGURE 8.1 – Emplacement prévu pour une capture du dashboard (non disponible au moment de la rédaction)

Chapitre 9

RÉSULTATS ET CONSTATS

Les constats ci-dessous sont uniquement ceux établis par l'EDA et confirmés par les visualisations revues. Ils décrivent le jeu étudié.

Constats principaux :

- Les volumes sont globalement équilibrés entre entreprises, types de campagnes, audiences, localisations et segments (écarts de parts inférieurs à 0,4 point).
- Le rythme est d'environ 548 campagnes par jour civil.
- Février est plus faible en volume brut en raison de ses 28 jours, pas d'une baisse d'activité journalière distincte.
- Le CTR moyen vaut 14,04 % contre une médiane de 9,98 % (asymétrie à droite).
- Le ROI moyen est ≈ 5 (5,0024 ; médiane 5,0100) dans les différentes dimensions analysées.
- Les écarts de ROI moyen entre catégories restent faibles (0,005 à 0,038 selon la dimension).
- Les corrélations CTR/clicks ($r = +0,51$) et CTR/impressions ($r = -0,66$) sont liées à la définition du CTR.
- Il n'apparaît pas de gradient clair du ROI selon le CTR, la durée ou l'engagement.

Pas de causalité

Ces résultats sont descriptifs. Une corrélation, un écart de moyennes ou une différence de volume n'établit pas de mécanisme causal.

Chapitre 10

LIMITES DE L'ANALYSE

Contraintes :

- Les données sont observationnelles.
- L'analyse décrit des associations et des distributions ; elle ne permet pas d'établir une causalité.
- Le jeu est très équilibré : les volumes par modalité sont proches, ce qui limite la visibilité d'éventuels contrastes.
- Les différences de KPI entre catégories sont souvent très faibles ; une échelle trop zoomée les exagérerait.
- Les corrélations CTR / clics / impressions sont en partie mécaniques, car le CTR est un ratio de ces deux grandeurs.
- Les résultats sont limités au dataset étudié (200 005 campagnes de 2021) et ne doivent pas être généralisés au-delà.
- Le CTR moyen des campagnes (moyenne des ratios) n'est pas égal au CTR global (∑ clics / ∑ impressions) ; les deux indicateurs répondent à des questions différentes.

Aucune recommandation d'allocation budgétaire, de ciblage ou de choix de canal n'est formulée à partir de ces écarts.

Chapitre 11

CONCLUSION

Le projet a mis en place une chaîne complète, reproductible, allant du fichier Excel à un dashboard Python, en passant par PostgreSQL, SQL, Pandas, une EDA et seize visualisations Matplotlib revues.

La chaîne technique est volontairement simple : une table relationnelle unique, des lectures SQL, une préparation Pandas bornée (calendrier et CTR), des analyses descriptives, des graphiques honnêtes sur les échelles, une restitution Streamlit filtrable. PostgreSQL et les données sources n'ont pas été altérés après l'import.

Les enseignements portent sur la structure du jeu plus que sur des leviers d'action : volumes réguliers, ROI moyen proche de 5 quelle que soit la dimension, CTR asymétrique, corrélations du CTR largement définitionnelles, absence de gradient clair du ROI selon le CTR, la durée ou l'engagement.

L'intérêt du pipeline est de séparer clairement stockage, exploration, préparation, analyse, visualisation et restitution, et de conserver une traçabilité des contrôles de qualité (0 anomalie détectée).

Des évolutions possibles, non réalisées ici, consisteraient à ajouter une capture d'écran du dashboard dans ce rapport, à documenter d'autres jeux de données s'ils devenaient disponibles, ou à étendre la restitution sans changer le caractère descriptif de l'analyse. Aucune recommandation métier n'est déduite des écarts observés.

Annexe A

CONTRÔLES QUALITÉ

TABLE A.1 – Synthèse des contrôles de qualité

Contrôle	Résultat
Nombre de lignes	200 005
Colonnes sources / après préparation	15 / 21
`campaign_id` unique	OK (1 à 200 005)
Valeurs manquantes	0
Infinis	0
Dates hors 2021	0
CTR cohérent avec clics / impressions	OK
Valeurs sources inchangées après EDA	OK
Anomalies de qualité	0

Annexe B

TABLEAUX SQL COMPLÉMENTAIRES

B.1 Volumes par entreprise

TABLE B.1 – Campagnes par entreprise (SQL / briefing)

Entreprise	*n*	Part	ROI moyen
TechCorp	40 238	20,12 %	5,01
Alpha Innovations	40 051	20,02 %	5,01
DataTech Solutions	40 014	20,01 %	5,01
NexGen Systems	39 991	20,00 %	4,99
Innovate Industries	39 711	19,86 %	5,00

B.2 Classes de ROI (`CASE`)

TABLE B.2 – Classes de ROI calculées en SQL

Classe	Campagnes	ROI moyen
Faible (ROI $<$ 4)	66 503	2,9946
Moyen (4 $\leq$ ROI $<$ 6)	66 438	4,9983
Élevé (ROI $\geq$ 6)	67 064	6,9975

B.3 Types de campagnes

TABLE B.3 – Effectif et ROI moyen par type de campagne

Type	Campagnes	ROI moyen
Influencer	40 170	5,0110
Search	40 157	5,0084
Display	39 988	5,0065
Email	39 871	4,9943
Social Media	39 819	4,9918

Annexe C

VISUALISATIONS COMPLÉMENTAIRES

Les figures suivantes complètent le chapitre 7. Elles proviennent du même script Matplotlib et de la même revue.

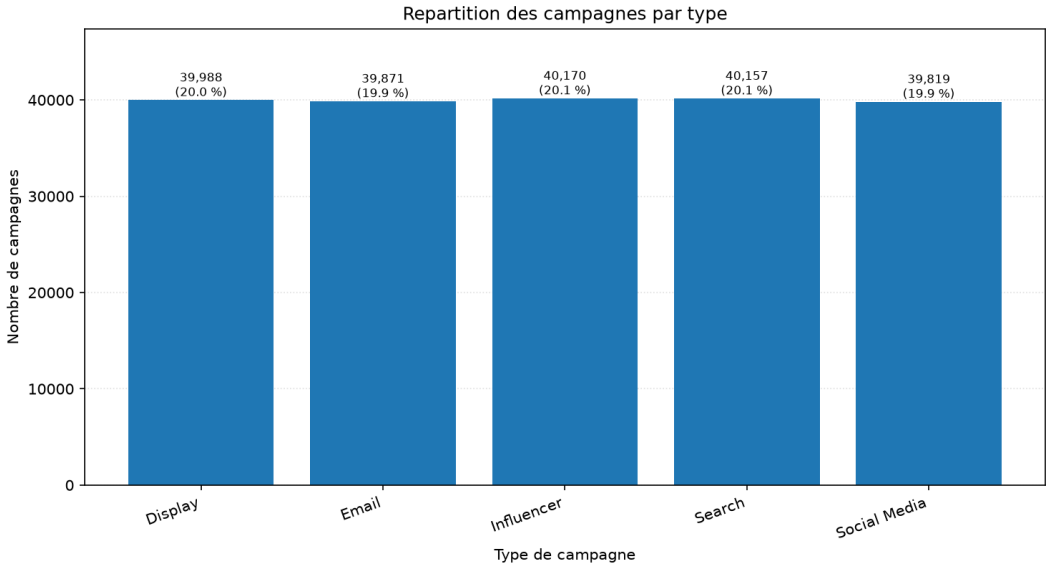


FIGURE C.1 – Volume par type de campagne

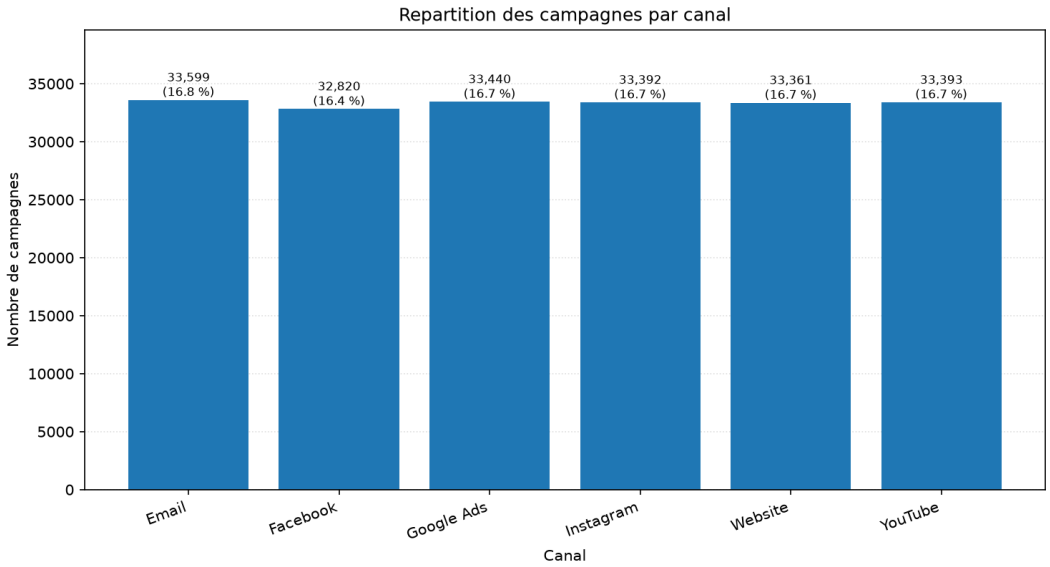


FIGURE C.2 – Volume par canal

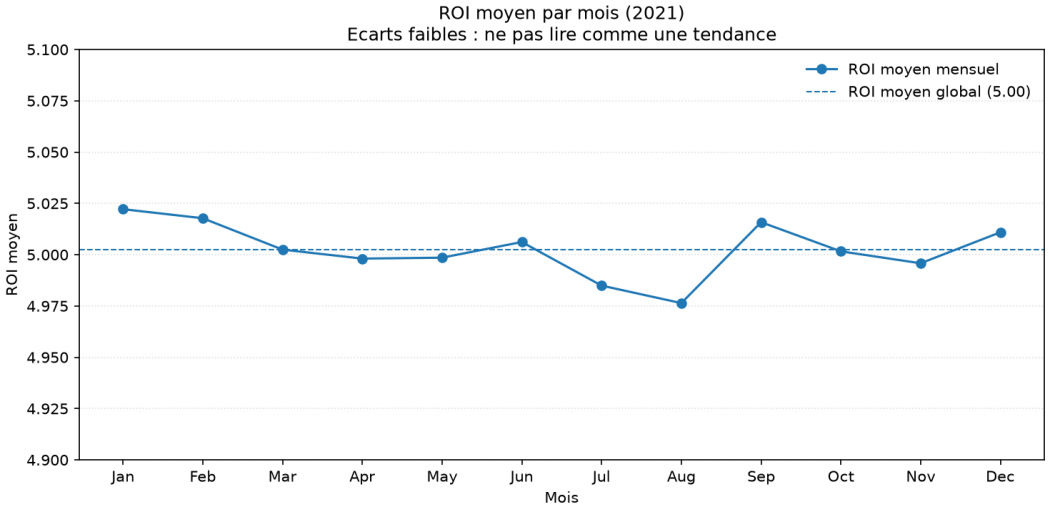


FIGURE C.3 – ROI moyen mensuel (écarts faibles)

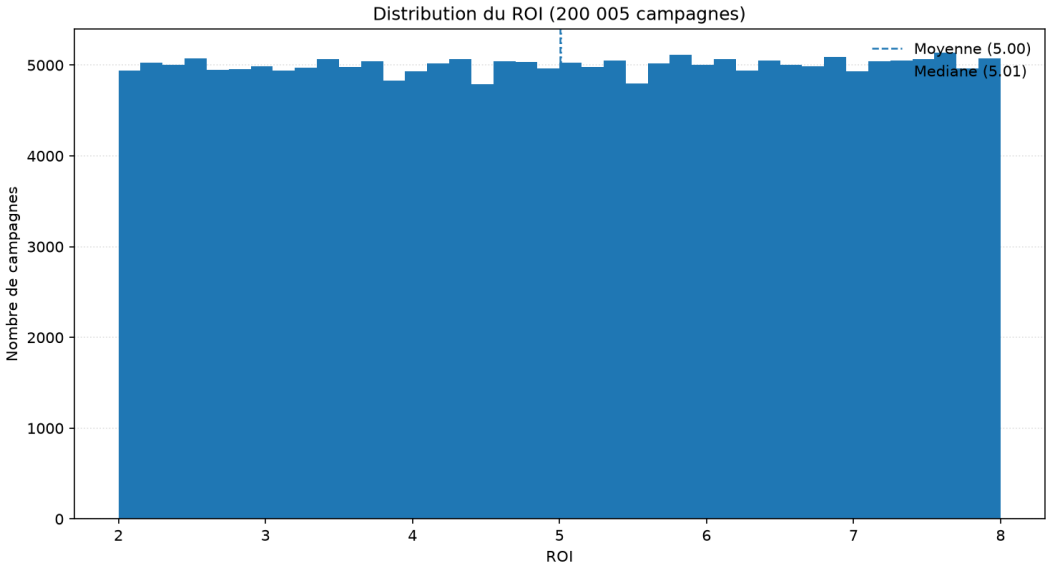


FIGURE C.4 – Distribution du ROI

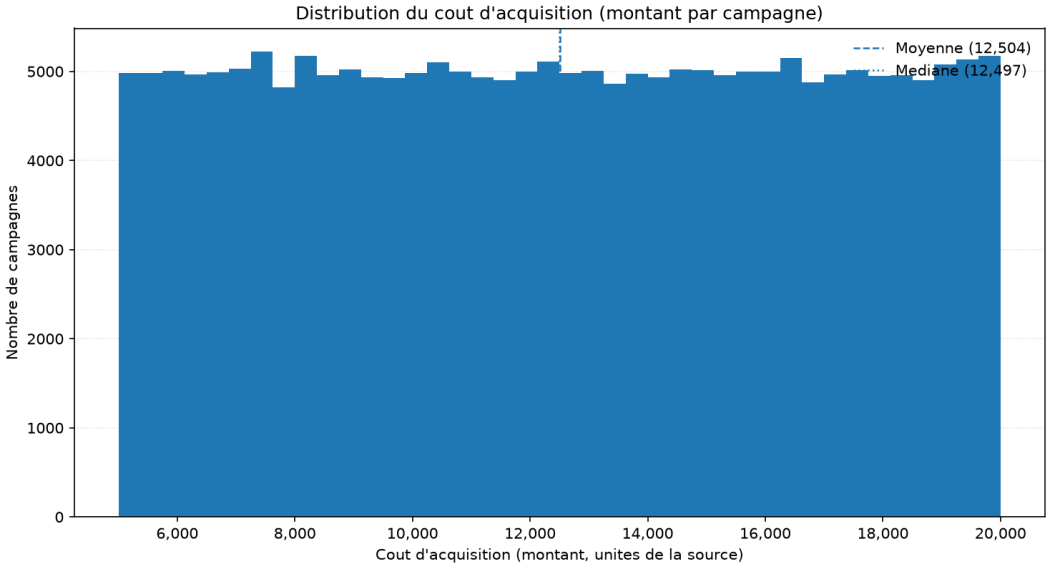


FIGURE C.5 – Distribution du coût d'acquisition

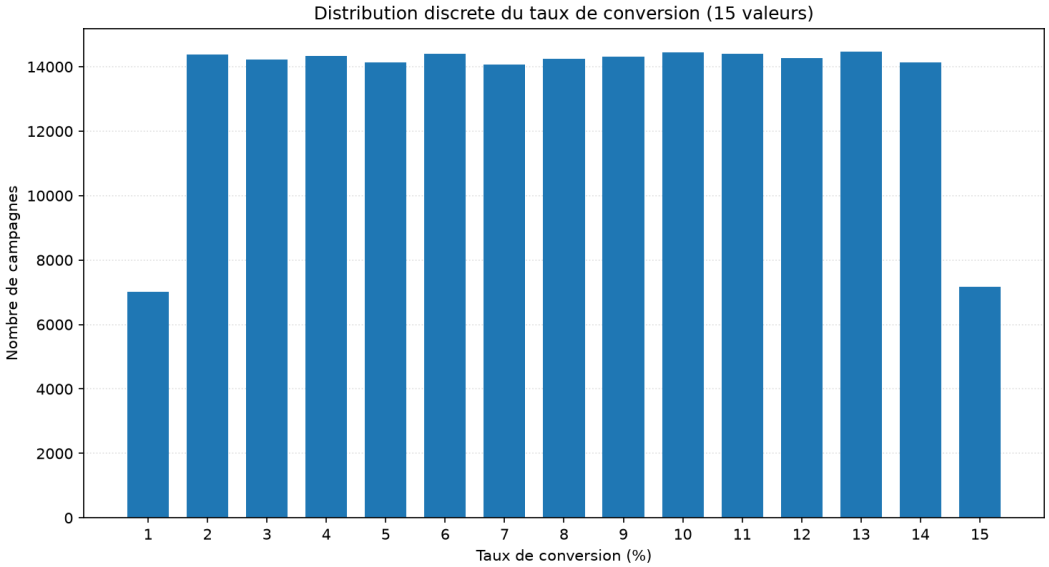


FIGURE C.6 – Distribution discrète du taux de conversion

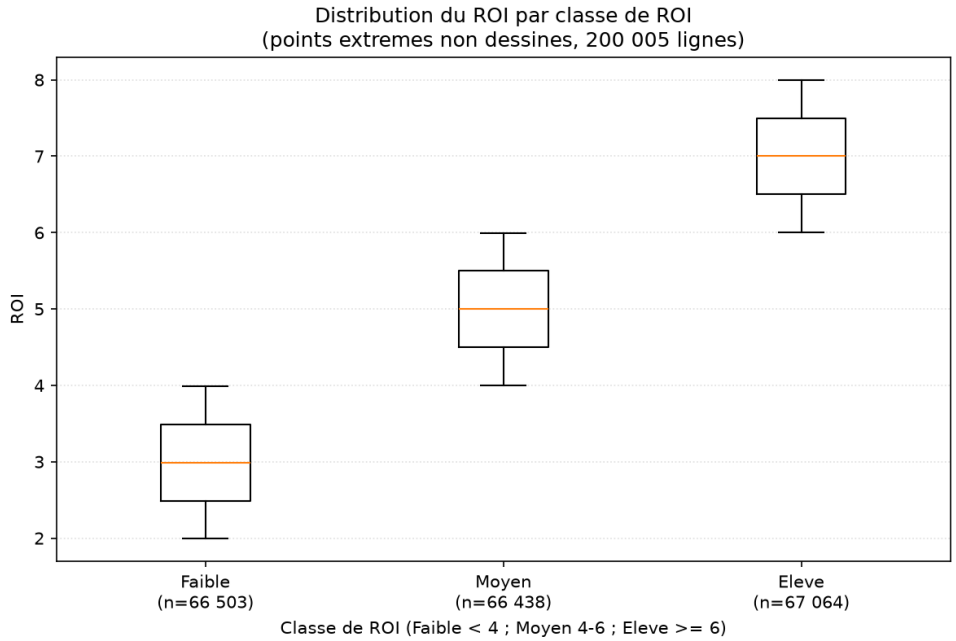


FIGURE C.7 – Distribution du ROI par classe de ROI

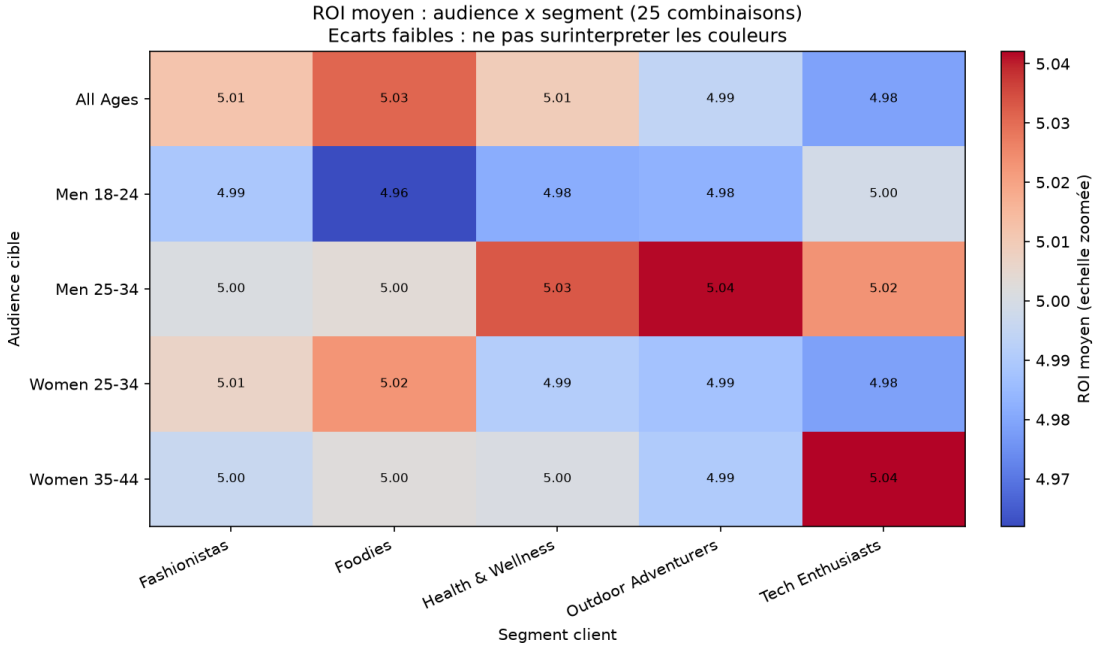


FIGURE C.8 – ROI moyen : audience × segment

Les écarts observés sont faibles ; ils ne permettent pas d'établir une différence forte entre les combinaisons.

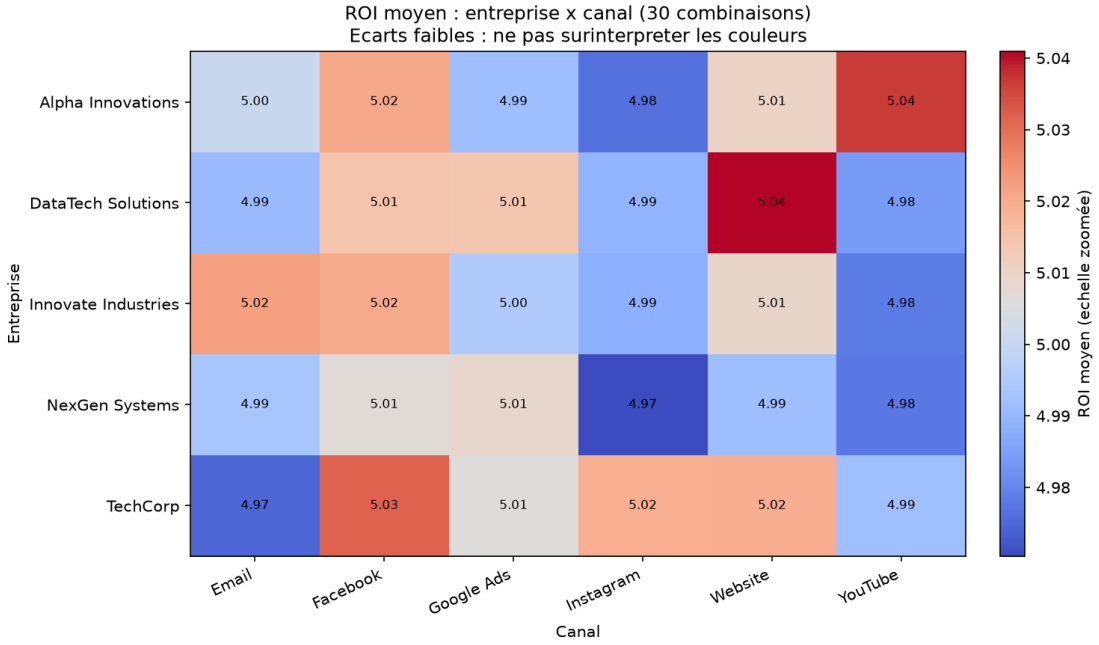


FIGURE C.9 – ROI moyen : entreprise × canal (pas un classement)

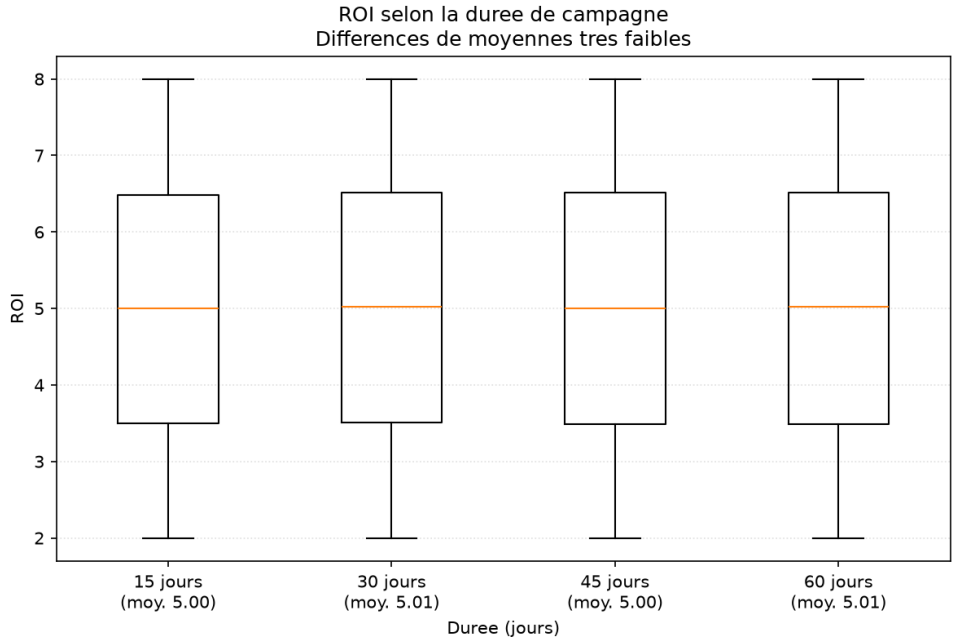


FIGURE C.10 – ROI selon la durée de campagne

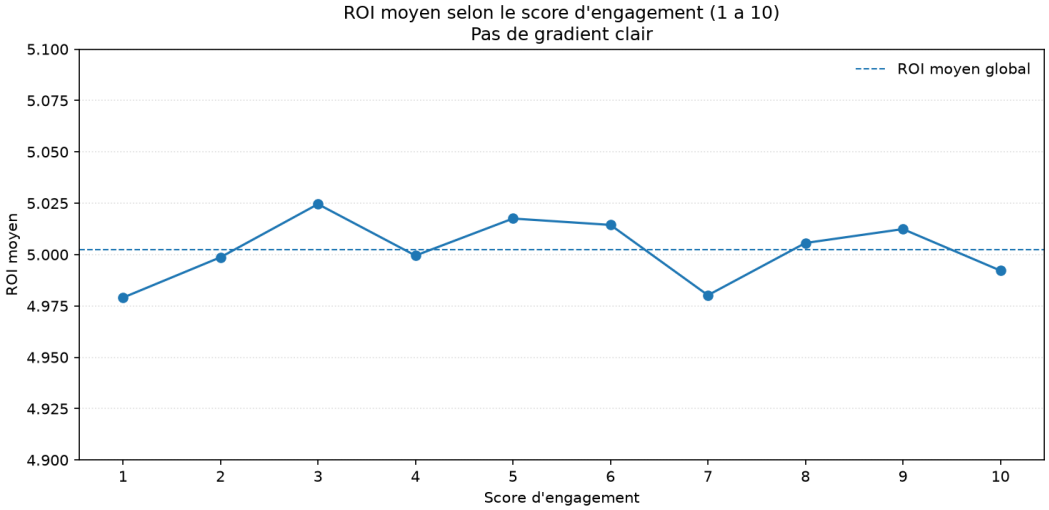


FIGURE C.11 – ROI moyen selon le score d'engagement

Annexe D

STRUCTURE DU PROJET ET SCRIPTS

TABLE D.1 – Scripts analytiques du projet

Fichier	Rôle
`postgres_to_python.py`	Extraction PostgreSQL → Pandas
`python_dataframe_profil`	Profilage et préparation (21 colonnes)
`python_eda.py`	EDA A–S, sans graphique
`python_visualisations.p`	16 figures Matplotlib
`dashboard.py`	Dashboard Streamlit

Le présent rapport LaTeX se trouve dans `report/`. Le modèle de mise en page provient du dépôt GitHub `sikatikenmogne/latex-report-template`, licence MIT SIKATI KENMOGNE, 2025. Le dépôt amont n'a pas été modifié : seule une copie de travail a été adaptée.

Compilation : `python scripts/compile.py` depuis `report/`, puis copie du PDF vers `rapport_analyse_marketing.pdf`.

BIBLIOGRAPHIE

THE PANDAS DEVELOPMENT TEAM. (2026). *pandas documentation* [Bibliothèque Python d'analyse de données tabulaires]. https://pandas.pydata.org/docs/

HUNTER, J. D., & THE MATPLOTLIB DEVELOPMENT TEAM. (2026). *Matplotlib documentation* [Bibliothèque Python de visualisation scientifique]. https://matplotlib.org/stable/

STREAMLIT INC. (2026). *Streamlit documentation* [Framework Python pour applications de restitution analytique]. https://docs.streamlit.io/

THE POSTGRESQL GLOBAL DEVELOPMENT GROUP. (2025). *PostgreSQL 18 Documentation* [Documentation officielle du système de gestion de bases de données relationnelles]. https://www.postgresql.org/docs/18/

SOURCE DU PROJET. (2021). marketing_campaign_dataset [Fichier Excel local marketing_campaign_dataset.x 200 005 campagnes, période 2021-01-01 – 2021-12-31. Jeu utilisé tel quel, sans publication académique associée].

BAYER, M., & THE SQLALCHEMY AUTHORS. (2025). *SQLAlchemy 2.0 Documentation* [Boîte à outils SQL et mapping objet-relationnel pour Python]. https://docs.sqlalchemy.org/

SIKATI KENMOGNE, S. (2025). Professional LaTeX Report Template [Modèle de mise en page utilisé pour le présent rapport]. https://github.com/sikatikenmogne/latex-report-template